




Inteligencia Artificial Generativa y LLMs

Fundamentos para entender qué es, de dónde viene y cómo se usa

IBootcamp Data Science

¿Qué es la Inteligencia Artificial?



Inteligencia Artificial

Que las máquinas hagan tareas que asociamos con la inteligencia humana (decidir, reconocer, traducir).

Machine Learning

La máquina aprende de ejemplos en lugar de seguir reglas escritas a mano.

Deep Learning

Redes neuronales con muchas capas. Es lo que disparó los avances recientes.

IA Generativa

El subconjunto que nos ocupa: en vez de clasificar, crea contenido nuevo.

Una breve historia

De las primeras ideas a la explosión actual. El salto clave llegó en 2017.

1950s



Nace la idea

Test de Turing y primeros modelos. La IA empieza como concepto.

1980-2010



Aprende de datos

Auge del machine learning y las redes neuronales.

2017



Transformers

El artículo 'Attention is all you need' cambia las reglas del juego.

2018-2022



Era GPT

GPT-1/2/3 y, en nov. 2022, ChatGPT lo populariza para todos.

2023-2026



Explosión

Modelos multimodales, más baratos y los primeros agentes.

¿Qué es la IA Generativa?

La diferencia clave: la IA tradicional analiza; la generativa crea.



IA tradicional

Responde preguntas cerradas: ¿es spam o no? ¿cuánto valdrá? Clasifica y predice sobre datos existentes.



IA generativa

Produce contenido nuevo que no existía: un texto, una imagen, una respuesta, un programa.

¿Qué puede generar?



Texto

Artículos, resúmenes, correos, respuestas



Imágenes

Ilustraciones y diseños a partir de una frase



Audio

Voz, música y efectos de sonido



Vídeo

Clips generados desde una descripción




Código

Programas y scripts a partir de instrucciones

¿Qué es un LLM?

Large Language Model — Gran Modelo de Lenguaje. Es el motor de la IA generativa de texto.



Una definición sencilla

Un programa entrenado con cantidades enormes de texto (libros, webs, código) hasta aprender los patrones del lenguaje.

Con eso es capaz de comprender lo que le pides y generar una respuesta coherente, palabra a palabra.

Detrás de estas herramientas hay un LLM:

ChatGPT → modelos GPT

Claude → modelos Claude


Gemini → modelos Gemini

Copilot, Perplexity...

¿Cómo funciona un LLM? (en sencillo)

No 'piensa' como nosotros: predice la siguiente palabra más probable, una y otra vez.

Es como un autocompletado llevado al extremo



El modelo calcula qué palabra es la más probable para continuar: 'azul' (90%), 'gris' (6%), 'naranja' (2%)...



Aprende patrones

Durante el entrenamiento ve billones de palabras y deduce cómo se relacionan.



No memoriza frases

Genera cada respuesta desde cero; por eso puede crear texto original.



No consulta una base

Salvo que se le conecte, responde con lo aprendido, no con datos en vivo.

Conceptos clave (I): tokens y parámetros

Dos palabras que oirás constantemente. Conviene tenerlas claras.



Token

Es la unidad mínima de texto que maneja el modelo: un trozo de palabra.

‘inteligencia’ ≈ 3 tokens. Aprox. 1 token = 4 caracteres = $\frac{3}{4}$ de palabra.

Importa porque el precio y los límites se miden en tokens.



Parámetros

Son los ‘ajustes’ internos que el modelo afina al entrenar. Definen lo que sabe.

Los grandes modelos tienen decenas o cientos de miles de millones de parámetros.

Más parámetros ≈ más capacidad, pero también más coste y lentitud.

Conceptos clave (II): contexto y memoria

Cuánto 'recuerda' en una conversación y de dónde viene su conocimiento.



Entrenamiento

El proceso (largo y costoso) de aprender de los datos. Se hace una vez; luego el modelo se usa muchas veces.



Ventana de contexto

Su 'memoria de trabajo': cuánto texto puede tener presente a la vez. Hoy va de miles a millones de tokens.



Fecha de corte

El conocimiento del modelo llega hasta una fecha. No sabe nada posterior salvo que se le conecte a internet.

El prompt: cómo le hablamos a la IA

El prompt es la instrucción que le damos. La calidad de la respuesta depende muchísimo de él.



Anatomía de una buena instrucción

- ▶ **Rol / contexto** *“Actúa como profesor de historia...”*
- ▶ **Tarea concreta** *“Resume este texto en 5 puntos”*
- ▶ **Formato deseado** *“Devuélvelo como lista numerada”*
- ▶ **Ejemplos (opcional)** *Muéstrale uno o dos casos modelo*



Temperatura

Controla la creatividad: baja = respuestas predecibles y precisas; alta = más variadas y arriesgadas.



System prompt

Instrucción 'oculta' que fija el comportamiento general del asistente antes de que el usuario escriba.


Limitaciones que hay que conocer

Son herramientas potentes, pero no infalibles. Saber esto evita disgustos.



Alucinaciones

A veces inventan datos con total seguridad. Hay que verificar lo importante.



Sesgos

Reflejan los sesgos presentes en los datos con los que se entrenaron.



Conocimiento caducado

No conocen hechos posteriores a su fecha de corte.



Cálculo y lógica

Pueden fallar en matemáticas exactas o razonamientos largos.



No 'entienden'

Predicen lenguaje; no tienen conciencia ni intenciones reales.



Privacidad

Cuidado con enviar datos sensibles a servicios de terceros.

Ejemplos de modelos actuales (2026)

El panorama cambia cada pocas semanas. Estos son los referentes a mediados de 2026.

GPT-5.5

OpenAI *Cerrado*

Muy versátil; ecosistema y multimedia integrados.

Claude Opus 4.8

Anthropic *Cerrado*

Referente en código, razonamiento y seguridad.

Gemini 3.1 Pro

Google *Cerrado*

Contexto enorme (millones de tokens) y multimodal.

Grok 4

xAI *Cerrado*

Integrado en el ecosistema de X.

Llama 4

Meta *Abierto*

Descargable y ejecutable en tu propia infraestructura.

DeepSeek / Qwen / Mistral

Varios *Abierto*

Alternativas abiertas con muy buena relación calidad-precio.

Modelos abiertos vs. cerrados

Dos filosofías. Ninguna es 'mejor': depende de lo que necesites.



Cerrados (API)

GPT, Claude, Gemini, Grok

- Máxima capacidad de frontera
- No necesitas servidores ni mantenimiento
- Integración rápida y soporte
- Pagas por uso; tus datos salen a un tercero



Abiertos (open source)

Llama, Mistral, DeepSeek, Qwen

- Privacidad total si lo ejecutas tú
- Control y personalización (fine-tuning)
- Sin coste por token si tienes el hardware
- Requiere infraestructura y conocimientos

El dilema precio / rendimiento

El coste varía hasta 60 veces entre modelos. Y lo caro no siempre rinde más.

[Redacted]

[Redacted]

[Redacted]

[Redacted]



Cae sin parar

El coste por token ha bajado cerca de un 90% en año y medio.



Precio $\approx$ calidad

En tareas reales, la correlación entre precio y calidad es casi nula.



Velocidad cuenta

Modelos pequeños y rápidos bastan para la mayoría de tareas.

Estrategia: un modelo para cada tarea

La práctica habitual no es elegir 'el mejor', sino combinar varios según la necesidad.

Tarea compleja o crítica

Usa un modelo potente (Opus, GPT-5.5, Gemini Pro).
Más caro, pero más fiable cuando importa.

Tarea rutinaria de alto volumen

Usa un modelo rápido y barato (Qwen, Llama, modelos abiertos). Ahorras mucho sin perder calidad útil.

4 factores para decidir



Capacidad

¿Qué dificultad tiene?



Velocidad

¿Necesita ser instantáneo?



Coste

¿Cuántas llamadas harás?



Privacidad

¿Hay datos sensibles?

Acceso a los modelos: OpenRouter

Una sola puerta de entrada a cientos de modelos. Es lo que usaremos en el curso.



OpenRouter

Tu código → una sola API → el modelo que elijas



Una API, cientos de modelos 300+ modelos de 60+ proveedores con una única clave.



Compatible con OpenAI Si tu código habla con OpenAI, funciona cambiando solo la URL.



Capa gratuita Decenas de modelos a 0 € (con límites) para aprender y probar.



Cambias de modelo en 1 línea Pruebas y comparas sin tocar el resto del programa.

Resumen



La IA generativa crea contenido nuevo; los LLM son su motor para el texto.



Un LLM predice la siguiente palabra: ni memoriza ni consulta datos en vivo por defecto.



Tokens, contexto y fecha de corte explican sus límites (incluidas las alucinaciones).



Hay muchos modelos: abiertos vs. cerrados, y un fuerte dilema precio / rendimiento.



Accederemos a todos ellos con una sola herramienta: OpenRouter.