

Machine Learning –Support Vector Machines


Intro SVM

Definición

Algoritmo supervisado de Machine Learning capaz de resolver problemas lineales, no lineales, de clasificación y regresión.


Es uno de los modelos más utilizados debido a su versatilidad y precisión.

Son algoritmos sensibles al escalado, por lo que se suelen estandarizar antes del entrenamiento.



Definición

- Hiperplano.
- Margen de decision.
- Vectores de soporte.



Hiperplano

Es un subespacio plano y afín (no tiene por qué pasar por el origen), de dimensión $p-1$, que divide el espacio en dos mitades.


Todos los puntos que caigan en el hiperplano cumplirán:

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p = 0$$

O caerán a un lado u otro del hiperplano:

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p > 0$$

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p < 0$$



Hiperplano óptimo

Para un problema de clasificación binaria con buena separación de las clases, existen infinitos hiperplanos que los separen, pero solo un hiperplano óptimo que maximiza la distancia entre las observaciones y el hiperplano.

Hiperplano óptimo


Aquel que tenga la mayor distancia mínima de las observaciones al hiperplano, el mayor margen.

Support Vector

Son los vectores que aguantan (soportan) al hiperplano óptimo de separación. Si estos cambian, el hiperplano también lo hará. El movimiento del resto de observaciones no tiene impacto

SVM: separable classes


Support vectors uniquely characterize optimal hyper-plane



Hard margin classifier

Son los clasificadores que utilizan un hiperplano óptimo. Presentan ciertos problemas:

- Son sensibles a overfitting.
- Funcionan si los datos están linealmente separados.
- Muy sensible a outliers




Soft margin classifier

Hiper plano que no separa perfectamente las clases, permitiendo que algunas observaciones caigan del lado incorrecto.

Ahora los support vectors serán tanto los que se encuentren en el margen como los que violen el margen.

Esta flexibilidad se controla mediante C . Cuanto menor es C , más es la flexibilidad/tolerante es mi modelo, y por tanto generalizará mejor. Más robusto, y por tanto, menos overfitting.




Nonlinear Support Vector Classifier

Nonlinear SVC

Los SVC lineales funcionan muy bien, pero para problemas lineales, que en la vida real son problemas poco frecuentes.


Una posible solución es introducir nuevas features polinómicas (feature expansion). El problema es que las regresiones polinómicas no se adaptan bien a datasets complejos, y le añaden demasiada complejidad al modelo, provocando que sea muy lento y podamos caer en overfitting.



¿Qué es un Kernel?


El kernel es una función matemática que calcula el resultado final directamente en el espacio original (2D), pero el resultado que arroja es matemáticamente idéntico al que obtendrías si hubieras hecho todo el viaje de subir los datos a 3D, calcular las distancias y volver.

En resumen: El Kernel simula un espacio de dimensiones superiores sin obligar al ordenador a transformar los datos físicamente. Es como tener los beneficios de vivir en un palacio 3D pagando el alquiler de un piso 2D.



Kernels

- **Kernel Lineal (kernel='linear'):**
Asume que los datos ya se pueden separar con una línea recta
- **Kernel Polinómico (kernel='poly'):**
Eleva los datos a potencias (al cuadrado, al cubo, etc.). Si tus datos originales están en 2D, el kernel polinómico calcula las relaciones como si estuvieran en un espacio de curvas y parábolas.
- **Kernel RBF o Gaussiano (kernel='rbf'):**
Este kernel conceptualmente proyecta los datos a un espacio de infinitas dimensiones.




Support Vector Regression

Support Vector Regression

Podemos utilizar SVM para algoritmos de regresión. A diferencia de clasificación, el objetivo es el inverso, SVMRegression intenta ajustarse al máximo para que abarque la mayor cantidad de muestras.

La anchura de los márgenes la controlaremos con el hiperparámetro ε , que es la tolerancia, cuanto más bajo, peor generalizará.

También podemos usar kernels para problemas no lineales.



Parametros de Support Vector Classifier

Parametros SVC

- **Kernel:** Define la función matemática que se usará para medir la similitud entre los puntos.
- **C :** Controla la tolerancia del modelo a los errores de clasificación. Un “C” muy alto el modelo es muy estricto. Para conseguirlo, estrechará el margen tanto como haga falta.

```
modelo_svm = SVC(  
    kernel="rbf",  
    C=1.0,  
    gamma="scale",  
    probability=True,  
    class_weight=None,  
    random_state=42  
)
```


Parametros SVC

- **Gamma:** Define qué tan lejos llega la influencia de un solo vector de soporte. Es decir, determina si el modelo se fija solo en los puntos más cercanos o si tiene una visión más global.

```
modelo_svm = SVC(  
    kernel="rbf",  
    C=1.0,  
    gamma="scale",  
    probability=True,  
    class_weight=None,  
    random_state=42  
)
```

Parametros SVC

- **probability:** Si es "True", usará un método interno (Calibración de Platt) para poder usar ".predict_proba()".
- **class_weight:** el algoritmo penalizará más los errores en la clase minoritaria para que no sea ignorada.

```
modelo_svm = SVC(  
    kernel="rbf",  
    C=1.0,  
    gamma="scale",  
    probability=True,  
    class_weight=None,  
    random_state=42  
)
```

Parametros de Support Vector Classifier

Parametros SVC

- **Epsilon:** Define el ancho de la "calle" alrededor de la línea de predicción. Cualquier punto del dataset que caiga dentro de esta calle tiene una penalización.
- **C:** Controla cuánto se penaliza a los puntos que se salen de la calle definida por "epsilon".

```
model_svr = SVR(  
    kernel='rbf',  
    C=10.0,  
    epsilon=0.1,  
    gamma='scale'  
)
```

Ventajas

1. Efectivo con muchas features
2. Eficaz computacionalmente
3. Varios kernels para varios problemas
4. Clasificación/Regresión
5. Robustos frente overfitting
6. Robustos frente outliers

Desventajas

1. Mal performance si n° features $> n^{\circ}$ samples
2. Hay que realizar mucha combinatoria de kernels e hiperparámetros para conseguir el modelo óptimo
3. Es caja negra