



RAG

Acceso a datos

Bootcamp Data Science - IA Agentica

El problema

Un LLM, por potente que sea, tiene tres límites importantes.



No conoce TUS datos

No ha visto tus documentos, manuales ni la información privada de tu empresa.



Fecha de corte

No sabe lo que ha pasado después de su entrenamiento. Su conocimiento se queda "congelado".



Alucinaciones

Cuando no sabe algo, a veces se lo inventa con total seguridad. Difícil de detectar.

¿Qué es RAG?

Antes de responder, el sistema **BUSCA** información relevante en tus documentos y se la **PASA** al modelo para que responda con ella.



1. Buscar

Encuentra los fragmentos que tienen que ver con la pregunta.



2. Aumentar

Añade esos fragmentos al prompt como contexto.



3. Generar

El modelo responde basándose en esa información.

La analogía: examen a libro abierto

La forma más fácil de entender RAG.



LLM normal = examen de memoria

Responde con lo que recuerda de su entrenamiento. Si no lo sabe, improvisa.



RAG = examen a libro abierto

Le dejamos consultar "el libro" (tus documentos) justo antes de responder. Menos errores y respuestas fundamentadas.

Cómo funciona: dos fases

Una se hace una vez; la otra, en cada pregunta.



Fase A · Indexar (una vez)

Preparas tus documentos y los guardas en un formato "buscable". Es la biblioteca del sistema.

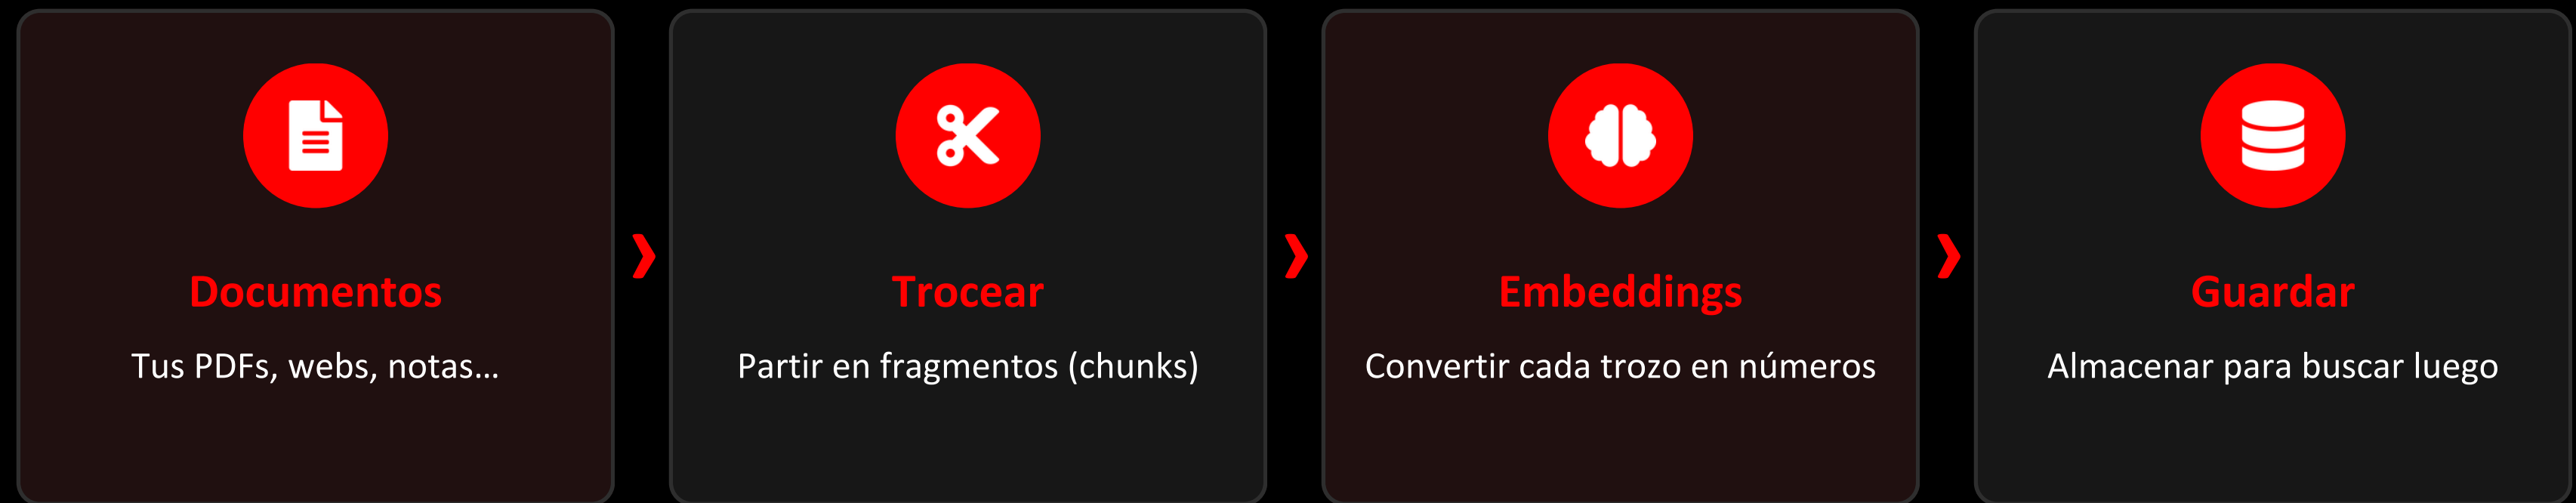


Fase B · Consultar (cada pregunta)

Buscas los fragmentos relevantes y el modelo responde con ellos. Es lo que ocurre en tiempo real.

Fase A · Indexar, paso a paso

De tus documentos a una "biblioteca" que se puede buscar.



Trocear es importante: fragmentos del tamaño justo se buscan mejor que un documento entero.

¿Qué es un embedding?

La pieza "mágica" que permite buscar por significado.

Convertir un texto en una lista de números (un vector) que captura su **SIGNIFICADO**. Textos parecidos → vectores cercanos.



Cerca (significado parecido)

"perro" y "gato" quedan cerca: ambos son mascotas.




Lejos (poco que ver)

"perro" y "factura del banco" quedan lejos.

Fase B · Consultar, paso a paso

Lo que pasa cada vez que alguien pregunta.



El modelo solo ve los fragmentos relevantes, no toda tu documentación: así es rápido y barato.

RAG vs. otras opciones

¿Cuándo conviene cada una?



Solo prompt

Rápido y simple, pero el modelo NO conoce tus datos privados ni los recientes.



Fine-tuning (reentrenar)

Enseñas al modelo con ejemplos. Potente, pero caro, lento y el conocimiento se queda fijo.



RAG

El modelo consulta datos frescos y actualizables, y puede citar fuentes. Ideal si tu información cambia.

Buenas prácticas

Cuatro detalles que marcan la diferencia.



Tamaño del chunk

Ni tan grande que mezcle temas, ni tan pequeño que pierda contexto.



Calidad de la búsqueda

Si recuperas fragmentos malos, la respuesta será mala. "Basura entra, basura sale".



Cita las fuentes

Mostrar de qué documento sale cada dato hace la respuesta verificable.



Mantenlo al día

La gran ventaja de RAG: actualizar la biblioteca es tan fácil como cambiar los documentos.